

Projet d'Analyse de données - Alzheimer

Julien Eyraud - Alexandre Goignard - Tidiane Bah - Luca Michelangeli

24/11/2025

Contexte et problématique de la maladie d'Alzheimer

La maladie d'Alzheimer est une maladie neurodégénérative progressive affectant principalement la mémoire, le raisonnement et le langage. Elle représente la forme la plus courante de démence, touchant entre 60 et 70 % des cas de démence dans le monde (Organisation Mondiale de la Santé, 2023), notamment en Europe, Amérique du Nord et Asie.

Plus de **55 millions de personnes** vivent actuellement avec une forme de démence, et ce chiffre pourrait atteindre **139 millions** d'ici 2050 (Alzheimer's Disease International, 2023). En France, environ **1,2 million de personnes** sont concernées, avec près de **225 000 nouveaux cas** chaque année (Fondation Médéric Alzheimer, 2024). La prévalence augmente fortement avec l'âge, touchant plus de 20 % des personnes de plus de 85 ans, et les femmes sont deux fois plus susceptibles d'être atteintes que les hommes (Ministère de la Santé, 2023).

Le vieillissement de la population laisse prévoir un quasi-doublement des cas en France d'ici 2050 (France Alzheimer, 2024). Les conséquences sont multiples : augmentation des coûts de santé, besoin accru de structures spécialisées et charge sur les aidants familiaux, ce qui souligne l'importance du dépistage précoce et de la recherche thérapeutique.

Présentation du jeu de données


Le jeu de données utilisé pour cette analyse a été extrait de la plateforme Kaggle et est spécifiquement conçu pour l'étude des facteurs de risque et le diagnostic de la maladie d'Alzheimer.

Il contient **2149 observations** au total, représentant chacune un dossier patient unique avec un ensemble de **35 variables** descriptives. Ces variables englobent une variété d'informations cruciales, notamment des données démographiques (comme l'âge), des facteurs de style de vie (tels que le tabagisme, l'activité physique et l'IMC), des antécédents médicaux (incluant les maladies cardiovasculaires et le diabète), ainsi que l'état de santé général du patient.


Des mesures plus spécifiques de l'état cognitif et fonctionnel sont également incluses, comme le score au **MMSE** (Mini Mental State Examination), l'évaluation fonctionnelle (**Functional Assessment**) et la présence de plaintes liées à la mémoire (**Memory Complaints**).

L'objectif principal de notre modélisation est de **prédire la variable cible nommée Diagnosis**. Il s'agit d'une **variable binaire** qui indique le statut du patient par rapport à la maladie.

$$\text{Diagnosis} = \begin{cases} 0 & \text{si le patient n'est pas atteint de la maladie d'Alzheimer} \\ 1 & \text{si le patient est atteint de la maladie d'Alzheimer} \end{cases}$$




(a) Barplot - vital status distribution




(b) Boxplot - age at diagnosis by vital status

Figure 1: Exploration of patient vital status distribution and its relationship with age at diagnosis.

As shown in Figure 1a, the cohort includes 1,029 alive patients and 201 deceased patients. Moreover, Figure 1b shows that the mean age at diagnosis is lower among alive patients (58.5 years) compared with those who died (61.6 years), suggesting an age-related difference in survival outcomes.




(a) Barplot - tumor distribution




(b) Barplot - Tumor subtype vs vital status

Figure 2: Overall tumor type distribution and subtype differences according to vital status.



(a) Barplot - Vital Status by T stage



(b) Barplot - Follow ups disease response by race


Figure 3: Vital status across AJCC T-stages and follow-up disease response by race.

Figure 2a shows that infiltrating duct carcinoma, NOS (857 cases) is the predominant tumor type, followed by lobular carcinoma, NOS (195 cases). Survival differences across subtypes are notable (Figure 2b): medullary carcinoma has the highest mortality (57%), whereas infiltrating lobular mixed carcinoma shows 100% survival. Vital status also varies strongly with AJCC T-stage (Figure 3a). Early-stage tumors such as T1c show low mortality (10%), while more advanced stages perform considerably worse, with T2b at 100% mortality and T4d at 75%. Finally, follow-up disease responses differ across races (Figure 3b). Asian patients exhibit the lowest rate of persistent disease

(3.3%), followed by White patients (11.8%) and Black or African American patients (12.7%), suggesting disparities in post-treatment outcomes.

Clustering : grouping genes together

We cluster genes using **k-means** to simplify visualisation, assuming genes with related expression patterns group together. Because genes must be treated as observations, the dataset is transposed so genes form the rows. To select the **optimal number of clusters k** , we use methods (PAM-CLARA), and assess cluster quality using two complementary metrics: within-cluster sum of squares (WSS) and average silhouette width.



(a) Graphs of methods to determine k . (b) Visualisation of genes clustering ($k = 4$) using PCA

Figure 4: Determination of the optimal number of clusters and visualization of genes clustering.

The silhouette width remains relatively high and the elbow plot begins to flatten around this value around $k = 4$ clusters. 4 clusters is optimal for grouping for the GeneX genes.